# 高性能计算程序设计基础 秋季 2021

## 提交格式说明

按照实验报告模板填写报告，需要提供源代码及代码描述至 https://easyhpc.net/course/129。实验报告模板使用 PDF 格式，命名方式为高性能计算程序设计_学号_姓名。如果有问题，请发邮件至 jiangjzh6@mail2.sysu.edu.cn，liuyh73@mail2.sysu.edu.cn 询问细节。

## 任务 1：

通过 CUDA 实现通用矩阵乘法（Lab1）的并行版本，CUDA Thread Block size 从 32 增加至 512，矩阵规模从 512 增加至 8192。

通用矩阵乘法（GEMM）通常定义为：

$$\mathrm{C} = \mathrm{AB}$$

$$C_{\mathrm{m,n}} = \sum_{n=1}^{N} A_{m,n} B_{n,k}$$

输入：M , N, K 三个整数（512 ~8192）

问题描述：随机生成 M*N 和 N*K 的两个矩阵 A,B,对这两个矩阵做乘法得到矩阵 C。

输出：A,B,C 三个矩阵以及矩阵计算的时间

## 任务 2：

通过 NVDIA 的矩阵计算函数库 CUBLAS 计算矩阵相乘，矩阵规模从 512 增加至 8192，并与任务 1 和任务 2 的矩阵乘法进行性能比较和分析，如果性能不如 CUBLAS，思考并文字描述可能的改进方法（参考《计算机体系结构-量化研究方法》第四章）。

CUBLAS 参考资料《CUBLAS_Library.pdf》，CUBLAS 矩阵乘法参考第 70 页内容。

CUBLAS 矩阵乘法例子，参考附件《matrixMulCUBLAS》

## 任务 3：

在信号处理、图像处理和其他工程/科学领域，卷积是一种使用广泛的技术。在深度学习领域，卷积神经网络(CNN)这种模型架构就得名于这种技术。在本实验中，我们将在 GPU 上实现卷积操作，注意这里的卷积是指神经网络中的卷积操作，与信号处理领域中的卷积操作不同，它不需要对 Filter 进行翻转，不考虑 bias。

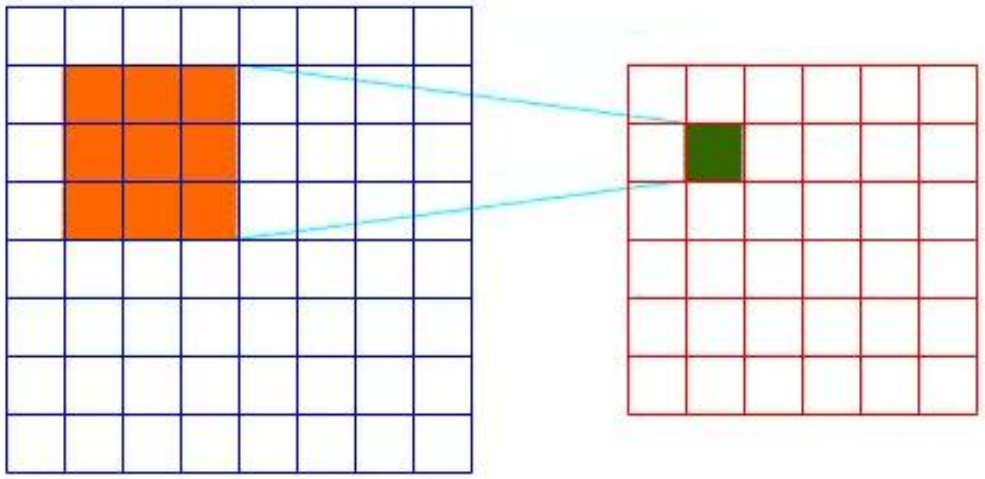

任务一通过 CUDA 实现直接卷积（滑窗法），输入从 256 增加至 4096 或者输入从 32 增加至 512.

输入：Input 和 Kernel(3x3)

问题描述：用直接卷积的方式对 Input 进行卷积，这里只需要实现 2D, height*width，通道 channel(depth)设置为 3，Kernel (Filter)大小设置为 3*3，步幅(stride)分别设置为 1，2，3，可能需要通过填充(padding)配合步幅(stride)完成 CNN 操作。注：实验的卷积操作不需要考虑 bias(b)，bias 设置为 0.

输出：输出卷积结果以及计算时间

以下是部分 CNN 操作的解释 ppt，具体参考附件中的人工智能课件。

1）CNN Input Image 举例

# Convolution Layer

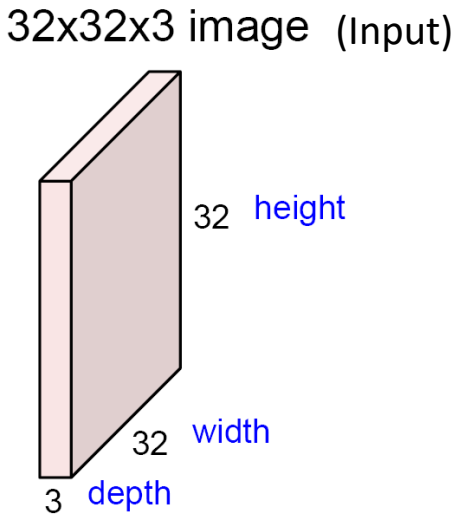


2）CNN Input Image 和 Kernel(Filter)

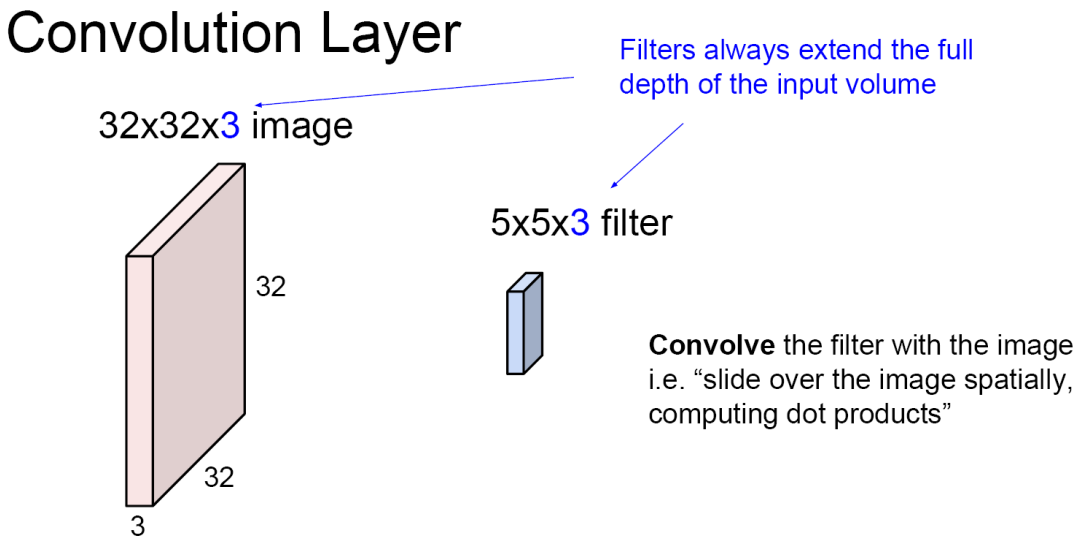

## Convolution Layer

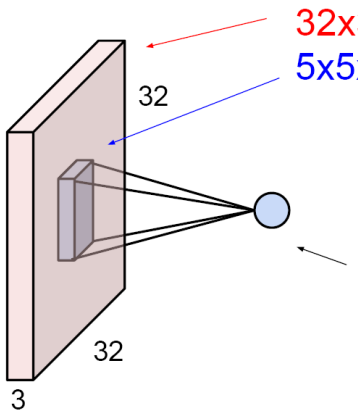


**1 number:**
the result of taking a dot product between the filter and a small 5x5x3 chunk of the image
(i.e. 5*5*3 = 75-dimensional dot product + bias)

$$w^T x + b$$

3)CNN 操作过程

## Convolution Layer

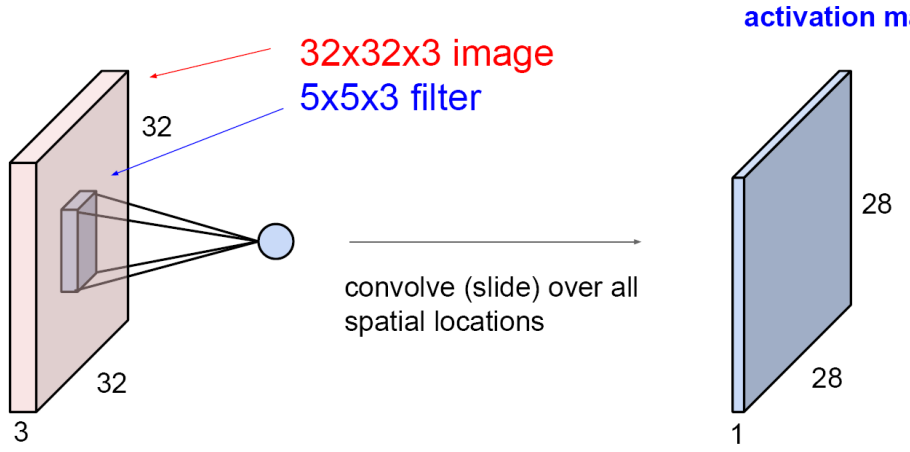

For example, if we had 6 5x5 filters, we'll get 6 separate activation maps:

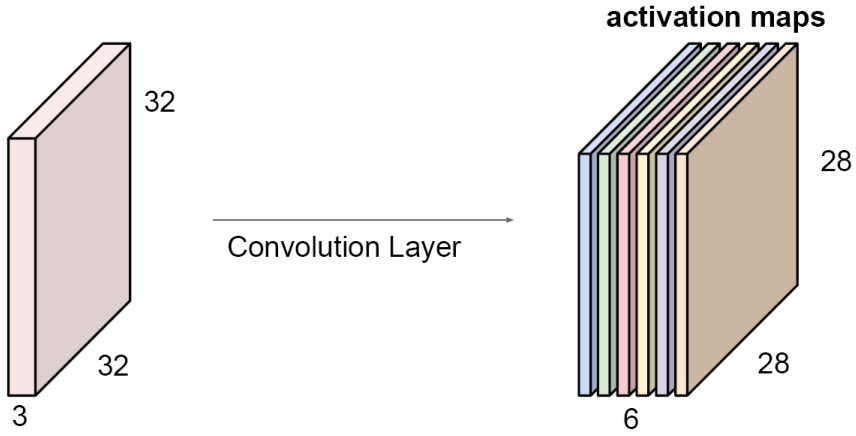


We stack these up to get a "new image" of size 28x28x6!

4) CNN 步幅 stride 和填充 padding

A closer look at spatial dimensions:

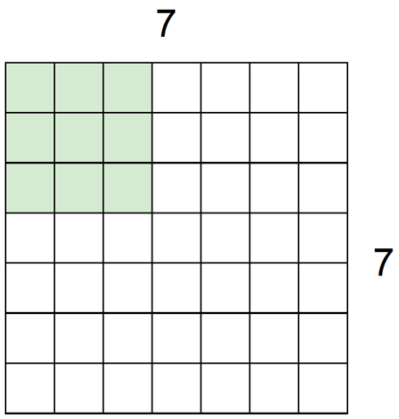


7x7 input (spatially)
assume 3x3 filter
applied **with stride 3?**

**doesn't fit!**
cannot apply 3x3 filter on
7x7 input with stride 3.

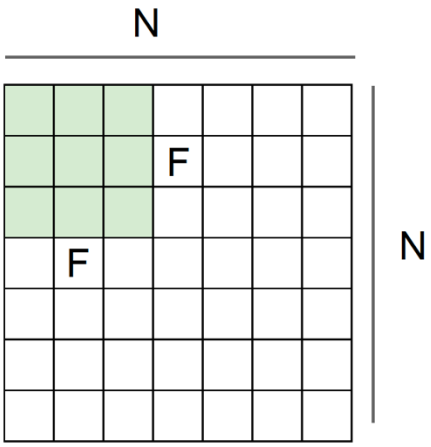


Output size:
**(N - F) / stride + 1**

e.g. N = 7, F = 3:
stride 1 => (7 - 3)/1 + 1 = 5
stride 2 => (7 - 3)/2 + 1 = 3
stride 3 => (7 - 3)/3 + 1 = 2.33

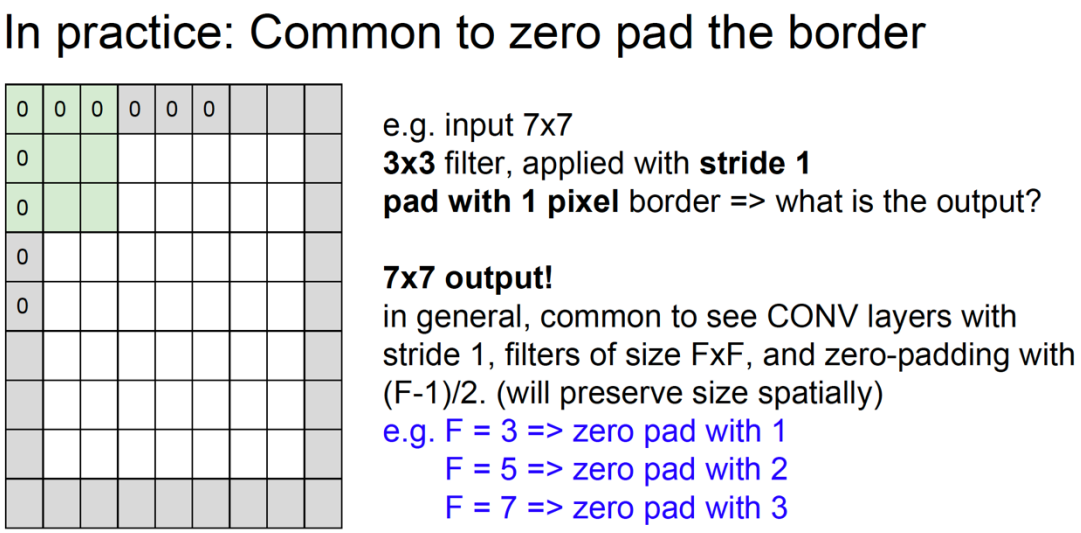


## 任务 4：

使用 im2col 方法结合任务 1 实现的 GEMM（通用矩阵乘法）实现卷积操作。输入从 256 增加至 4096 或者输入从 32 增加至 512，具体实现的过程可以参考下面的图片和参考资料。

输入：Input 和 Kernel (Filter)

问题描述：用 im2col 的方式对 Input 进行卷积，这里只需要实现 2D, height*width，通道 channel(depth)设置为 3，Kernel (Filter)大小设置为 3*3。 注：实验的卷积操作不需要考虑 bias(b)，bias 设置为 0，步幅(stride)分别设置为 1，2，3。

输出：卷积结果和时间。

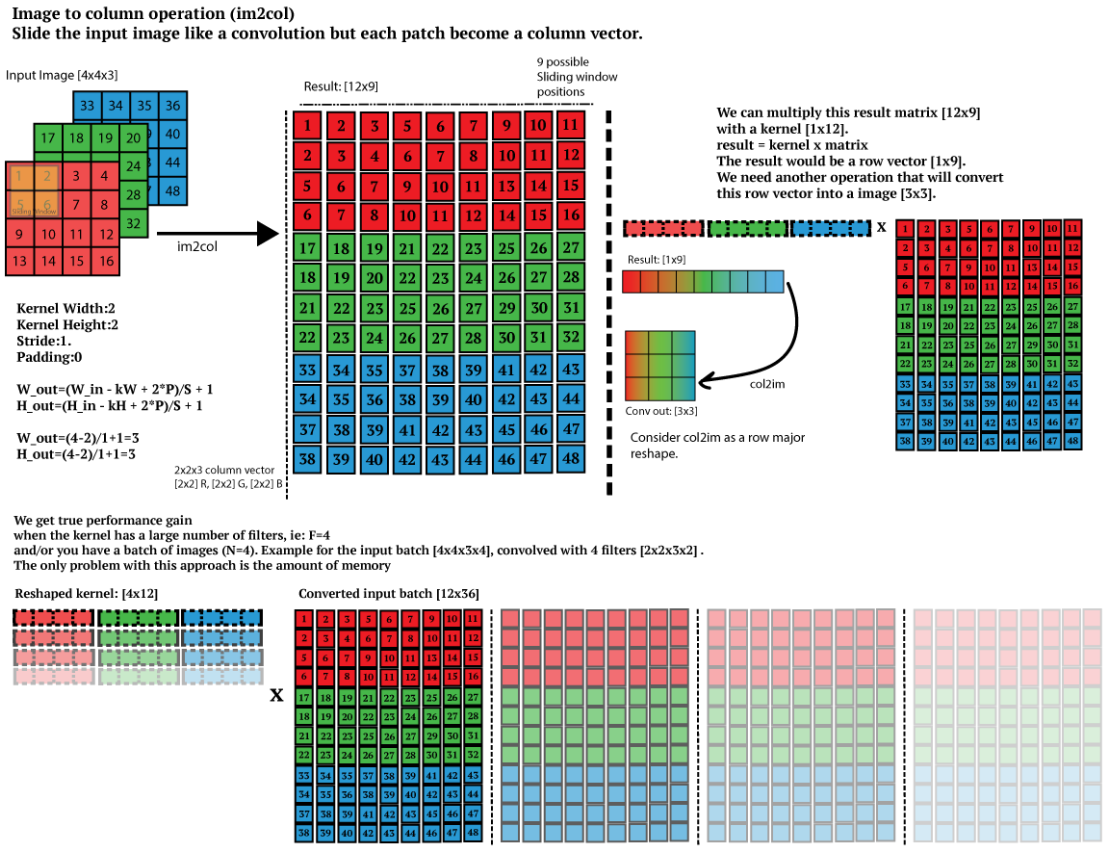


# 任务 5：

NVIDIA cuDNN 是用于深度神经网络的 GPU 加速库。它强调性能、易用性和低内存开销。

使用 cuDNN 提供的卷积方法进行卷积操作，记录其相应 Input 的卷积时间，与自己实现的卷积操作进行比较。如果性能不如 cuDNN，用文字描述可能的改进方法。

# CNN 参考资料，见实验发布网站

斯坦福人工智能课件 Convolutional Neural Networks，by Fei-Fei Li & Andrej Karpathy & Justin Johnson

## 其他参考资料 （搜索以下关键词）

[1]如何理解卷积神经网络（CNN）中的卷积和池化

[2] Convolutional Neural Networks (CNNs / ConvNets)

https://cs231n.github.io/convolutional-networks/

[3]im2col 的原理和实现

[4]cuDNN 安装教程

[5] convolutional-neural-networks

https://stanford.edu/~shervine/teaching/cs-230/cheatsheet-convolutional-neural-networks